

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



Data Fitting - Phương Pháp OLS

Báo Cáo Đồ Án Số 2
Toán Ứng Dụng và Thống Kê - MTH00051

Sinh viên thực hiện:

24120010 - Trần Văn Tấn Khôi

24120028 - Cao Việt Cường

24120035 - Lê Thành Đạt

24120038 - Nguyễn Phú Đạt

24120054 - Mai Phan Nhật Hoàng

Giảng viên hướng dẫn:

Võ Nam Thục Đoan

Lê Nhật Nam

Thành phố Hồ Chí Minh, Ngày 8 tháng 6 năm 2026

BẢNG PHÂN CHIA CÔNG VIỆC

Link github đồ án: <https://github.com/TanKhoiTV/blues-estimator-project>

MSSV	Họ và tên	Phân công công việc
24120010	Trần Văn Tấn Khôi	...
24120028	Cao Việt Cường	...
24120035	Lê Thành Đạt	...
24120038	Nguyễn Phú Đạt	...
24120054	Mai Phan Nhật Hoàng	...

MỤC LỤC

MỤC LỤC	ii
1 Lý Thuyết Data Fitting và Minh Họa	1
1.1 Bài Toán Data Fitting và Mô Hình Hồi Quy Tuyến Tính	2
1.1.1 Bài toán tổng quát	2
1.1.2 Mô Hình Hồi Quy Tuyến Tính	2
1.2 Phương Pháp Bình Phương Tối Tiểu	4
1.2.1 Hàm mất mát (Loss Function)	4
1.2.2 Chứng minh nghiệm cực tiểu	4
1.3 Các Giả Thiết Gauss-Markov và Định lý Gauss-Markov	5
1.3.1 Các Giả Thiết Gauss-Markov	5
1.3.2 Định lý Gauss-Markov	6
1.4 Ma Trận Chiếu (Hat Matrix) và Tính Chất Hình Học của OLS	6
1.4.1 Định nghĩa	6
1.4.2 Tính chất	7
1.4.3 Ý nghĩa hình học	8
1.5 Các Chỉ Số Đánh Giá Mô Hình	9
1.6 Suy Diễn Thống Kê Cho Các Hệ Số	11
1.6.1 Phân phối mẫu của ước lượng OLS	11
1.6.2 Kiểm định t-test và khoảng tin cậy	12
1.7 Hiện Tượng Đa Cộng Tuyến	13
1.7.1 Khái niệm	13
1.7.2 Phương pháp kiểm tra	13

1.8	Hồi Quy Ridge	14
1.8.1	Hàm mất mát của hồi quy Ridge	14
1.8.2	Chứng minh nghiệm đóng cho hồi quy Ridge	14
1.8.3	Bản chất đánh đổi tính chệch và phương sai	15
1.9	Phân Tích Phần Dư	16
1.9.1	Đồ thị Residuals vs Fitted	16
1.9.2	Đồ thị Normal Q-Q	16
1.9.3	Đồ thị Scale - Location	17
1.9.4	Đồ thị khoảng cách Cook	18
1.10	Phương Pháp Kiểm Định Chéo	19
1.11	Phương Pháp Mô Phỏng Monte Carlo	20
1.11.1	Nguyên lý áp dụng	20
1.11.2	Ý nghĩa đặc biệt của mô phỏng Monte Carlo	21
1.12	Kết Quả Thực Nghiệm và Minh Họa Số Liệu	22
1.12.1	Kiểm chứng tính chất toán học của ma trận chiếu	22
1.12.2	Kết quả ước lượng OLS và phân tích ý nghĩa thống kê	22
1.12.3	Nhận xét về các đồ thị phân tích phần dư	23
1.12.4	Kiểm chứng định lý Gauss-Markov bằng mô phỏng Monte Carlo	25

2 Ứng Dụng Thực Tế 27

2.1	Giới Thiệu Bộ Dữ Liệu và Bài Toán	28
2.1.1	Giới thiệu bộ dữ liệu	28
2.1.2	Mục tiêu và ý nghĩa thực tế	28
2.1.3	Đặc tả của các thuộc tính quan trọng	29
2.2	Khảo Sát Dữ Liệu	30
2.2.1	Kiểm tra chất lượng dữ liệu ban đầu	30
2.2.2	Bảng thống kê mô tả	31

2.2.3	Khảo sát tương quan và Phân phối	32
2.3	Tiền Xử Lý Dữ Liệu	34
2.3.1	Chọn lọc biến cho quá trình xử lý	34
2.3.2	Xử lý dữ liệu khuyết thiếu	35
2.3.3	Phân tách dữ liệu chống rò rỉ	36
2.3.4	Kiểm tra đa cộng tuyến qua VIF	36
2.4	Xây Dựng và So Sánh Các Mô Hình	37
2.4.1	Mô hình OLS Cơ Bản	37
2.4.2	Mô hình OLS Chọn Biến	38
2.4.3	Mô hình Hồi Quy Ridge	39
2.4.4	Mô hình Hồi Quy Kernel Ridge	40
2.4.5	Kết luận mô hình tối ưu nhất	42
2.5	Phân Tích Phần Dư và Đặc Điểm Quan Trọng Nhất	43
2.5.1	Phân tích phần dư Ridge	43
2.5.2	Đặc điểm quan trọng nhất	44
3	Kết Luận	46
3.1	Tóm tắt kết quả đạt được	47
3.2	Khó khăn gặp phải	47
3.3	Bài học rút ra	47
	DANH MỤC CÁC BẢNG	49
	DANH MỤC CÁC HÌNH ẢNH	50

CHƯƠNG 1

Lý Thuyết Data Fitting và Minh Họa

1.1. Bài Toán Data Fitting và Mô Hình Hồi Quy Tuyến Tính

1.1.1. Bài toán tổng quát

Trong các nghiên cứu về thực nghiệm và khoa học dữ liệu, ta thường xuyên gặp bài toán xấp xỉ hàm để tìm ra quy luật mô tả mối quan hệ giữa các biến số. Giả sử, ta có một tập dữ liệu gồm n quan sát như sau:

$$\mathcal{D} = \{(x_{i1}, x_{i2}, \dots, x_{ip}, y_i)\}_{i=1}^n \quad (1.1)$$

Trong đó:

- $y_i \in \mathbb{R}$ là biến phụ thuộc hay là biến mục tiêu cần dự đoán.
- $X_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \in \mathbb{R}^p$ là vector gồm p biến độc lập hay là biến giải thích.

Mục tiêu của bài toán là tìm một hàm số toán học $f(X)$ đóng vai trò xấp xỉ tốt nhất các giá trị y_i , tức là $y_i \approx f(X_i)$.

1.1.2. Mô Hình Hồi Quy Tuyến Tính

Xét một trong những mô hình phổ biến và nền tảng nhất chính là **Mô hình hồi quy tuyến tính bội**. Mô hình giả định mối quan hệ giữa các biến phụ thuộc và các biến độc lập là tuyến tính đối với các tham số. Mô hình được biểu diễn dưới dạng các phương trình đại số sau với mỗi quan sát i :

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \epsilon_i, \forall i = 1, 2, \dots, n \quad (1.2)$$

Trong đó:

- β_0 là hệ số chặn (Intercept).
- $\beta_1, \beta_2, \dots, \beta_p$ là các hệ số hồi quy ứng với từng biến độc lập.
- ϵ_i là sai số ngẫu nhiên (nhiều - noise) đại diện cho phần biến động của y_i mà các biến độc lập trong mô hình không giải thích được.

Hệ phương trình gồm n dòng trên được tổng quát hóa dưới dạng ma trận để thuận tiện cho việc biến đổi toán học và tính toán:

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\epsilon} \quad (1.3)$$

Định nghĩa chi tiết các thành phần trong phương trình trên:

- $y \in \mathbb{R}^{n \times 1}$ là vector cột chứa các giá trị của biến phụ thuộc.

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

- $X \in \mathbb{R}^{n \times (p+1)}$ là ma trận thiết kế (Design Matrix) với cột đầu tiên chứa toàn hệ số 1 nhằm tích hợp hệ số chặn β_0 vào phép nhân ma trận.

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

- $\boldsymbol{\beta} \in \mathbb{R}^{(p+1) \times 1}$ là vector cột chứa toàn bộ hệ số cần ước lượng.

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}$$

- $\boldsymbol{\epsilon} \in \mathbb{R}^{n \times 1}$ là vector cột chứa các sai số ngẫu nhiên.

$$\boldsymbol{\epsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

1.2. Phương Pháp Bình Phương Tối Thiểu

1.2.1. Hàm mất mát (Loss Function)

Ý tưởng cốt lõi của phương pháp bình phương tối thiểu (Ordinary Least Squares - OLS) là tìm kiếm vector tham số ước lượng $\hat{\beta}$ sao cho tổng bình phương các khoảng cách sai lệch giữa các giá trị thực tế y_i và giá trị dự báo $\hat{y}_i$ đạt giá trị nhỏ nhất. Tổng bình phương các khoảng cách trên được gọi là **Tổng bình phương phần dư** (Residual Sum Of Squares - RSS):

$$RSS(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2 \quad (1.4)$$

Biểu diễn dưới ma trận và chuẩn L_2 , hàm mất mát có dạng:

$$RSS(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) \quad (1.5)$$

1.2.2. Chứng minh nghiệm cực tiểu

Để tìm cực tiểu của hàm mất mát trên, ta tiến hành triển khai đại số biểu thức ma trận trên:

$$RSS(\beta) = (\mathbf{y}^T - \beta^T \mathbf{X}^T)(\mathbf{y} - \mathbf{X}\beta) \quad (1.6)$$

$$RSS(\beta) = \mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\beta - \beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X}\beta \quad (1.7)$$

Vì $\mathbf{y}^T \mathbf{X}\beta$ là một đại lượng vô hướng (scalar), nó bằng với chuyển vị của chính nó: $(\mathbf{y}^T \mathbf{X}\beta)^T = \beta^T \mathbf{X}^T \mathbf{y}$. Do đó, ta thu gọn được hàm mất mát thành:

$$RSS(\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X}\beta \quad (1.8)$$

Tiến hành lấy đạo hàm ma trận (Matrix Calculus) của hàm số theo vector tham số β :

$$\frac{\partial RSS(\beta)}{\partial \beta} = \mathbf{0} - 2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta \quad (1.9)$$

Để tìm điểm cực trị, ta thiết lập đạo hàm này bằng vector không $\mathbf{0}$:

$$-2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta = \mathbf{0} \implies \mathbf{X}^T \mathbf{X}\beta = \mathbf{X}^T \mathbf{y} \quad (1.10)$$

Phương trình trên được gọi là hệ Phương trình chuẩn tắc (Normal Equations) trong lý thuyết bình phương tối thiểu.

Để phương trình trên có nghiệm thì ma trận $X^T X$ phải khả nghịch. Khi đó, ta thu được công thức nghiệm duy nhất cho ước lượng OLS:

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T y \quad (1.11)$$

1.3. Các Giả Thiết Gauss-Markov và Định lý Gauss-Markov

1.3.1. Các Giả Thiết Gauss-Markov

Để phương pháp ước lượng bình phương tối thiểu (OLS) đạt được những tính chất thống kê tối ưu và các suy diễn kiểm định có hiệu lực thì mô hình phải bắt buộc thỏa mãn cả 5 giả thuyết Gauss-Markov sau đây:

1. Tuyến tính trong tham số (Linear in Parameters): Mỗi quan hệ giữa y và X được biểu diễn đúng dưới dạng tuyến tính $y = X\beta + \varepsilon$.
2. Không có đa cộng tuyến hoàn hảo (No Perfect Collinearity): Ma trận thiết kế X có hạng đầy đủ cột, nghĩa là $\text{rank}(X) = p + 1 < n$. Giả thiết này đảm bảo các cột của X độc lập tuyến tính với nhau, dẫn đến ma trận vuông $X^T X$ là một ma trận khả nghịch (không bị suy biến).
3. Kỳ vọng nhiễu bằng 0 (Zero Conditional Mean): Kỳ vọng của vector sai số khi biết ma trận thiết kế bằng vector không:

$$E[\varepsilon|X] = 0$$

Giả thiết này khẳng định sai số không chứa thông tin hệ thống và không có mối tương quan với các biến độc lập.

4. Phương sai nhiễu thuần nhất (Homoscedasticity): Phương sai của sai số ngẫu nhiên tại mọi quan sát là hằng số không đổi:

$$\text{Var}(\varepsilon_i|\mathbf{X}) = \sigma^2, \quad \forall i = 1, 2, \dots, n$$

5. Không có tự tương quan giữa các sai số (No Autocorrelation): Hiệp phương sai giữa hai sai số của hai quan sát khác nhau bất kỳ luôn bằng 0:

$$\text{Cov}(\varepsilon_i, \varepsilon_j|\mathbf{X}) = 0, \quad \forall i \neq j$$

Từ hai giả thuyết (4) và (5), ma trận hiệp phương sai của vector phần dư ϵ có dạng đơn vị hóa:

$$\text{Var}(\boldsymbol{\epsilon}|\mathbf{X}) = \sigma^2 \mathbf{I}_n$$

Trong đó, $\mathbf{I}_n$ là ma trận đơn vị kích thước $n \times n$.

1.3.2. Định lý Gauss-Markov

Định lý 1.1. Nếu một mô hình hồi quy tuyến tính thỏa mãn đầy đủ các giả thiết từ (1) đến (5), thì ước lượng Bình phương Nhỏ nhất $\hat{\beta}_{OLS}$ là ước lượng tuyến tính không chệch tốt nhất — BLUE (Best Linear Unbiased Estimator).

"Tốt nhất" mang ý nghĩa là trong tất cả các ước lượng tuyến tính và không chệch của β , ước lượng OLS là ước lượng đạt phương sai nhỏ nhất ($\text{Var}(\hat{\beta}_{OLS}) \leq \text{Var}(\tilde{\beta})$ với mọi ước lượng không chệch $\tilde{\beta}$ khác) nằm đảm bảo tính ổn định và tin cậy vượt trội của nghiệm OLS khi áp dụng trên thực nghiệm.

1.4. Ma Trận Chiều (Hat Matrix) và Tính Chất Hình Học của OLS

1.4.1. Định nghĩa

Sau khi thu được nghiệm tối ưu $\hat{\beta}_{OLS}$, vector các giá trị dự báo $\hat{\mathbf{y}}$ được tính toán qua công thức:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}_{OLS} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y} \quad (1.12)$$

Đặt ma trận, $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$, khi đó các giá trị dự báo có thể được viết lại dưới dạng:

$$\hat{\mathbf{y}} = \mathbf{H}\mathbf{y} \quad (1.13)$$

Ma trận H được gọi là **Ma trận mũ** (Hat Matrix) với vai trò biến vector quan sát thực tế $\mathbf{y}$ thành vector ước lượng $\hat{\mathbf{y}}$.

1.4.2. Tính chất

Tính đối xứng (Symmetry)

$$H^T = H \quad (1.14)$$

Chúng minh:

$$\mathbf{H}^T = [\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T]^T = (\mathbf{X}^T)^T [(\mathbf{X}^T\mathbf{X})^{-1}]^T \mathbf{X}^T$$

Vì $(\mathbf{X}^T)^T = \mathbf{X}$ và ma trận tích $\mathbf{X}^T\mathbf{X}$ là một ma trận đối xứng ($(\mathbf{X}^T\mathbf{X})^T = \mathbf{X}^T\mathbf{X}$), nên ma trận nghịch đảo của nó cũng là ma trận đối xứng, tức là $[(\mathbf{X}^T\mathbf{X})^{-1}]^T = (\mathbf{X}^T\mathbf{X})^{-1}$. Do đó, ta thu được:

$$\mathbf{H}^T = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T = \mathbf{H} \quad (\text{đpcm}) \quad (1.15)$$

Tính lũy đẳng (Idempotency)

$$H^2 = H \quad (1.16)$$

Chúng minh: Nhân ma trận $\mathbf{H}$ với chính nó

$$\mathbf{H}^2 = \mathbf{H}\mathbf{H} = [\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T] [\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T] \quad (1.17)$$

$$\mathbf{H}^2 = \mathbf{X} \cdot \underbrace{[(\mathbf{X}^T\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{X})]}_{\mathbf{I}_{p+1}} \cdot (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T \quad (1.18)$$

Vì $\mathbf{I}_{p+1}$ là ma trận đơn vị kích thước $(p+1) \times (p+1)$, ta có:

$$\mathbf{H}^2 = \mathbf{X} \cdot \mathbf{I}_{p+1} \cdot (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T = \mathbf{H} \quad (\text{đpcm})$$

Vết của ma trận (Trace property)

$$\text{trace}(\mathbf{H}) = p + 1 \quad (1.19)$$

Chúng minh:

$$\text{trace}(\mathbf{H}) = \text{trace}(\mathbf{X} \cdot [(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T]) = \text{trace}([(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T] \cdot \mathbf{X}) \quad (1.20)$$

$$\text{trace}(\mathbf{H}) = \text{trace}((\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X})) = \text{trace}(\mathbf{I}_{p+1}) = p + 1 \quad (\text{đpcm}) \quad (1.21)$$

1.4.3. Ý nghĩa hình học**Không gian con tuyến tính của các biến độc lập**

Xét ma trận thiết kế $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$ gồm vector biến độc lập $X_1, X_2, \dots, X_p$. Tập hợp tất cả các tổ hợp tuyến tính của các cột trên sẽ tạo thành một không gian con (Subspace), được gọi là **Không gian cột** của $\mathbf{X}$, ký hiệu là $\text{Col}(\mathbf{X}) \subset \mathbb{R}^n$. Chiều của không gian con bằng $\text{rank}(\mathbf{X}) = p + 1$.

Vector dữ liệu thực tế quan sát $\mathbf{y} \in \mathbb{R}^n$ là một điểm trong không gian n chiều. Tuy nhiên, do sự tác động ngẫu nhiên của nhiễu ϵ nên vector $\mathbf{y}$ hầu như luôn nằm ngoài không gian con $\text{Col}(\mathbf{X})$.

Mục tiêu hình học và Vector phần dư

Bất kỳ vector dự báo $\hat{\mathbf{y}}$ do mô hình tạo ra đều bắt buộc phải nằm trong không gian con $\text{Col}(\mathbf{X})$ do $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$.

Do đó, bài toán tối thiểu tổng bình phương phần dư $RSS = \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2$ tương đương với bài toán hình học: Tìm một điểm $\hat{\mathbf{y}}$ thuộc không gian con $\text{Col}(\mathbf{X})$ sao cho khoảng cách Euclide từ điểm $\mathbf{y}$ đến nó là ngắn nhất.

Khoảng cách từ một điểm đến một mặt phẳng (không gian con) đạt giá trị nhỏ nhất khi và chỉ khi đoạn thẳng nối giữa chúng vuông góc với mặt phẳng đó. Khi đó, vector $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ phải vuông góc hoàn toàn với mọi vector nằm trong $\text{Col}(\mathbf{X})$.

Điều kiện vuông góc được biểu diễn dưới dạng tích vô hướng như sau:

$$\mathbf{X}^T \mathbf{e} = \mathbf{0} \implies \mathbf{X}^T (\mathbf{y} - \hat{\mathbf{y}}) = \mathbf{0} \implies \mathbf{X}^T \mathbf{y} = \mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\beta}} \quad (1.22)$$

Đây chính là cách giải thích hình học trực quan tại sao ta thu được kết quả nghiệm đúng của ước lượng OLS.

Vai trò toán tử chiếu của Hat Matrix

Ma trận $\mathbf{H}$ chính là toán tử chiếu vuông góc. Khi ta thực hiện phép nhân ma trận $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$, ma trận $\mathbf{H}$ sẽ chiếu vuông góc từ đầu mút của vector $\mathbf{y}$ xuống không gian con $\text{Col}(\mathbf{X})$ để tìm ra vị trí tọa độ tối ưu $\hat{\mathbf{y}}$.

Mối liên hệ giữa tính chất của ma trận chiếu với ý nghĩa hình học:

- Tính đối xứng: Đảm bảo cho phép chiếu vuông góc không trở thành phép chiếu xiên, làm khoảng cách từ $\mathbf{y}$ đến không gian con là ngắn nhất.
- Tính lũy đẳng: Khi vector $\mathbf{y}$ đã được chiếu vuông góc xuống không gian con $\text{Col}(\mathbf{X})$ để trở thành $\hat{\mathbf{y}}$, điểm $\hat{\mathbf{y}}$ này đã nằm sẵn trên mặt phẳng. Nếu ta tiếp tục dùng toán tử $\mathbf{H}$ để chiếu nó lần thứ hai, vị trí của nó sẽ đứng yên không thay đổi ($\mathbf{H}\hat{\mathbf{y}} = \hat{\mathbf{y}}$).
- Tính chất vết ($\text{trace}(\mathbf{H}) = p + 1$): Vết của một ma trận chiếu vuông góc trong đại số tuyến tính luôn luôn bằng số chiều (dimension) của không gian con mà nó chiếu xuống. Trong bài toán hồi quy bội, số chiều này chính là số lượng tham số độc lập cần ước lượng ($p + 1$).

1.5. Các Chỉ Số Đánh Giá Mô Hình

Để định lượng hiệu năng và đo lường độ chính xác của hàm xấp xỉ dữ liệu thu được, lý thuyết hồi quy xây dựng một hệ thống các chỉ số đánh giá dựa trên việc phân rã tổng bình phương biến động (Sum of Squares Decomposition).

Chỉ số	Công thức toán học	Ý nghĩa
TSS (Total Sum of Squares)	$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$	Đo lường toàn bộ sự biến động của biến phụ thuộc y xung quanh giá trị trung bình mẫu $\bar{y}$ khi chưa có mô hình hồi quy.
ESS (Explained Sum of Squares)	$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	Phần biến động của biến mục tiêu được giải thích thành công bởi quy luật tuyến tính của các biến độc lập trong mô hình.
RSS (Residual Sum of Squares)	$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Phần sai lệch biến động còn sót lại do nhiễu ngẫu nhiên hoặc do mô hình bỏ sót biến, không thể giải thích được.
MAE (Mean Absolute Error)	$MAE = \frac{1}{n} \sum_{i=1}^n \ y_i - \hat{y}_i\ $	Giá trị trung bình của các sai lệch tuyệt đối giữa giá trị thực tế và giá trị dự báo.
RMSE (Root Mean Squared Error)	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Căn bậc hai của trung bình bình phương các sai lệch (độ lệch chuẩn của phần dư).

Bảng 1.1: Các chỉ số đo lường sự biến động trong mô hình hồi quy

Mối quan hệ toán học nền tảng giữa ba chỉ số: $TSS = ESS + RSS$.

- Hệ số xác định R^2 :

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

Chỉ số $R^2 \in [0, 1]$ biểu thị tỷ lệ phần trăm sự biến động của dữ liệu thực tế được giải

thích bởi mô hình. R^2 càng tiến gần tới 1 chứng tỏ hàm xấp xỉ càng khớp với dữ liệu thực nghiệm.

- Hệ số xác định hiệu chỉnh $\bar{R}^2$

Vì giá trị của R^2 luôn có xu hướng tăng lên hoặc giữ nguyên nếu xuất hiện thêm biến độc lập mới vào $\mathbf{X}$ dù cho biến mới đó không có ý nghĩa nên để giải quyết vấn đề overfitting thì $\bar{R}^2$ thêm cơ chế phạt dựa trên số lượng tham số p hiện có:

$$\bar{R}^2 = 1 - \left[\frac{RSS/(n-p-1)}{TSS/(n-1)} \right]$$

- Thống kê kiểm định F: Được sử dụng nhằm đánh giá ý nghĩa thống kê của toàn bộ mô hình tổng thể. Chỉ số này kiểm tra cặp giả thuyết:

□ $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ (Tất cả các biến độc lập đều không có tác động).

□ H_1 : Tồn tại ít nhất một hệ số $\beta_j \neq 0$ (Mô hình có ý nghĩa ít nhất với 1 biến).

Công thức toán học giá trị thống kê F :

$$F = \frac{ESS/p}{RSS/(n-p-1)}$$

1.6. Suy Diễn Thống Kê Cho Các Hệ Số

Để mở rộng bài toán hồi quy từ mức độ mô tả sang mức độ suy diễn thống kê tức là xác định xem một biến độc lập có thực sự ảnh hưởng đến biến phụ thuộc hay không, ta tiến hành kiểm định thống kê cho từng hệ số β_j .

Dưới giả thiết chuẩn GM5, ta có phân phối chuẩn của sai số:

$$\varepsilon|\mathbf{X} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n) \quad (1.23)$$

1.6.1. Phân phối mẫu của ước lượng OLS

Vì nghiệm $\hat{\beta}_{OLS}$ là một phép biến đổi tuyến tính của vector $\mathbf{y}$ nên vector ước lượng $\hat{\beta}$ cũng tuân theo phân phối chuẩn:

$$\hat{\beta}_{OLS} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}^T \mathbf{X})^{-1}) \quad (1.24)$$

Do phương sai nhiễu σ^2 trong thực tế không biết trước, ta sử dụng một ước lượng không chệch của nó trích xuất từ phương sai phần dư mẫu:

$$\hat{\sigma}^2 = \frac{RSS}{n - p - 1}$$

Khi đó, ma trận hiệp phương sai mẫu của các hệ số hồi quy được tính bằng:

$$\widehat{\text{Var}}(\hat{\beta}_{OLS}) = \hat{\sigma}^2(\mathbf{X}^T \mathbf{X})^{-1}$$

1.6.2. Kiểm định t-test và khoảng tin cậy

Sai số chuẩn (Standard Error): Căn bậc hai của các phần tử nằm trên đường chéo chính của ma trận $\widehat{\text{Var}}(\hat{\beta}_{OLS})$ chính là sai số chuẩn của từng hệ số hồi quy đơn lẻ, ký hiệu là $SE(\hat{\beta}_j)$.

Kiểm định giả thuyết t-test: Để đánh giá xem một biến độc lập x_j cụ thể nào đó có thực sự đóng góp ý nghĩa vào việc giải thích biến phụ thuộc y hay không, ta thực hiện kiểm định giả thuyết riêng lẻ:

$$H_0 : \beta_j = 0 \quad ; \quad H_1 : \beta_j \neq 0$$

Thống kê kiểm định t được xây dựng theo công thức:

$$t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

Dưới giả thuyết H_0 , giá trị t_j tuân theo phân phối Student t với bậc tự do là $(n - p - 1)$, từ đó ta tính ra giá trị xác suất **p-value**. Nếu $p\text{-value} < \alpha$ với mức nghĩa $\alpha = 0.05$ thì ta bác bỏ giả thuyết H_0 và kết luận biến đó có ý nghĩa thống kê.

Khoảng tin cậy (Confidence Interval): Khoảng tin cậy cấu thành mức độ dao động khả thi của tham số thực tế ở mức tin cậy $(1 - \alpha)$ được xác định bởi phương trình:

$$\left[\hat{\beta}_j - t_{\alpha/2, n-p-1} \cdot SE(\hat{\beta}_j), \quad \hat{\beta}_j + t_{\alpha/2, n-p-1} \cdot SE(\hat{\beta}_j) \right]$$

1.7. Hiện Tượng Đa Cộng Tuyến

1.7.1. Khái niệm

Đa cộng tuyến là hiện tượng các biến độc lập trong mô hình hồi quy tuyến tính bội có mối tương quan tuyến tính mạnh mẽ với nhau.

- **Đa cộng tuyến hoàn hảo:** Tồn tại các hệ số $\alpha_1, \alpha_2, \dots, \alpha_p$ không đồng thời bằng 0 sao cho $\alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_p X_p = 0$. Khi đó $\text{rank}(\mathbf{X}) < p + 1$, ma trận $\mathbf{X}^T \mathbf{X}$ không khả nghịch và thuật toán OLS hoàn toàn thất bại (không tìm được nghiệm).
- **Đa cộng tuyến không hoàn hảo:** Các biến không phụ thuộc tuyến tính tuyệt đối nhưng lại tương quan rất cao. Lúc này, định thức của $\mathbf{X}^T \mathbf{X}$ tiến gần về 0, làm cho các phần tử trên đường chéo chính của ma trận nghịch đảo $(\mathbf{X}^T \mathbf{X})^{-1}$ trở nên cực kỳ lớn.

Hệ quả: Vì phương sai của các hệ số ước lượng tỉ lệ thuận với đường chéo chính của $(\mathbf{X}^T \mathbf{X})^{-1}$, đa cộng tuyến sẽ làm cho sai số chuẩn $SE(\hat{\beta}_j)$ tăng vọt. Điều đó làm cho khoảng tin cậy của các hệ số bị nới rộng quá mức và giá trị thống kê t giảm mạnh, dẫn đến p-value lớn mô hình vô tình bác bỏ các biến có ý nghĩa.

1.7.2. Phương pháp kiểm tra

Để kiểm tra xem mức độ nghiêm trọng của đa cộng tuyến cho từng biến độc lập $\mathbf{X}_j$, ta sử dụng hệ số phóng đại phương sai (Variance Inflation Factor - VIF):

$$VIF_j = \frac{1}{1 - R_j^2}$$

Trong đó, R_j^2 là hệ số xác định (R^2) thu được từ mô hình hồi quy phụ khi ta dùng chính biến X_j làm biến phụ thuộc và hồi quy theo tất cả các biến độc lập còn lại trong mô hình.

Tiêu chuẩn đánh giá chỉ số VIF:

- $VIF_j = 1$: Biến X_j hoàn toàn không tương quan với các biến còn lại.
- $1 < VIF_j < 5$: Có tương quan vừa phải nhưng ở mức chấp nhận được, chưa gây ảnh hưởng nghiêm trọng.
- $VIF_j \geq 10$: Mô hình đang bị hiện tượng đa cộng tuyến nghiêm trọng. Phương sai của hệ

số $\hat{\beta}_j$ đã bị phóng đại lên ít nhất 10 lần, bắt buộc phải có biện pháp xử lý dữ liệu hoặc chuyển sang các phương pháp hồi quy nén (Regularization).

1.8. Hồi Quy Ridge

1.8.1. Hàm mất mát của hồi quy Ridge

Khi mô hình gặp hiện tượng đa cộng tuyến nghiêm trọng, phương pháp ước lượng OLS không còn tối ưu. Để khắc phục, Hồi quy Ridge (hay còn gọi là Regularization dạng L_2) được áp dụng bằng cách bổ sung một số hạng phạt vào hàm mất mát.

Hồi quy Ridge thay đổi mục tiêu tối ưu hóa bằng cách cộng thêm chuẩn L_2 (bình phương độ dài) của vector hệ số vào tổng bình phương phần dư (RSS):

$$Loss_{Ridge}(\beta) = RSS(\beta) + \lambda \|\beta\|_2^2 = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) + \lambda \sum_{j=1}^p \beta_j^2$$

Trong đó, $\lambda \geq 0$ là hệ số co cụm

- Nếu $\lambda = 0$: Hàm mất mát quay trở về dạng OLS truyền thống.
- Nếu $\lambda \rightarrow \infty$: Hình phạt quá lớn sẽ ép tất cả các hệ số hồi quy β_j tiệm cận dần về sát giá trị 0.

Trong thực tế, hệ số chặn β_0 thường không bị phạt trong tổng bình phương để tránh làm lệch mức nền trung bình của mô hình

1.8.2. Chứng minh nghiệm đóng cho hồi quy Ridge

Ta tiến hành triển khai hàm mất mát:

$$Loss_{Ridge}(\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta + \lambda \beta^T \beta$$

Lấy đạo hàm của hàm số theo vector tham số β :

$$\frac{\partial Loss_{Ridge}(\beta)}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta + 2\lambda \beta$$

Thiết lập cho đạo hàm bằng vector không $\mathbf{0}$ để tìm vị trí cực tiểu:

$$-2\mathbf{X}^T\mathbf{y} + 2\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} + 2\lambda\boldsymbol{\beta} = \mathbf{0} \implies (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})\boldsymbol{\beta} = \mathbf{X}^T\mathbf{y}$$

Ma trận $\mathbf{X}^T\mathbf{X}$ là ma trận nửa xác định dương. Khi cộng thêm $\lambda\mathbf{I}$ với $\lambda > 0$ đảm bảo ma trận $(\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})$ sẽ xác định dương và luôn khả nghịch, bất kể ma trận gốc $\mathbf{X}$ có đa cộng tuyến hay không.

Tuy nhiên, do hệ số chặn β_0 không gây nên hiện tượng đa cộng tuyến nên thành phần trên thường bị loại bằng cách triệt tiêu phần tử đầu tiên trên đường chéo chính của ma trận đơn vị. Khi đó, ta thu được nghiệm đóng của hồi quy Ridge:

$$\hat{\boldsymbol{\beta}}_{Ridge} = (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^T\mathbf{y}$$

1.8.3. Bản chất đánh đổi tính chệch và phương sai

Định lý Gauss-Markov chỉ ra rằng OLS là ước lượng không chệch có phương sai nhỏ nhất. Tuy nhiên, nếu hiện tượng đa cộng tuyến xảy ra thì phương sai nhỏ nhất trên vẫn quá lớn cho các ứng dụng thực tế. Hồi quy Ridge giải quyết bài toán trên bằng cách đánh đổi độ chệch và phương sai.

- Tính chệch: Ước lượng Ridge là một ước lượng bị chệch. Kỳ vọng toán học của nó không bằng tham số thực tế.

$$E[\hat{\boldsymbol{\beta}}_{Ridge}] = (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} \neq \boldsymbol{\beta}$$

Độ chệch này tăng dần khi λ tăng lên.


- Phương sai: Việc cộng thêm λ vào đường chéo chính giúp ổn định ma trận nghịch đảo, giảm biên độ dao động của các hệ số.

$$\text{Var}(\hat{\boldsymbol{\beta}}_{Ridge}) < \text{Var}(\hat{\boldsymbol{\beta}}_{OLS})$$

1.9. Phân Tích Phần Dư

1.9.1. Đồ thị Residuals vs Fitted

Đồ thị kiểm tra tính tuyến tính của mô hình và dấu hiệu đầu tiên của phương sai sai số đồng đều. Trục hoành biểu diễn các giá trị dự báo $\hat{y}_i$, trục tung biểu diễn các giá trị phần dư e_i .



Hình 1.1: Đồ thị Residuals vs Fitted


Mô hình lý tưởng: Các điểm phần dư phải phân tán một cách ngẫu nhiên, tạo thành một "đám mây" đối xứng ổn định xung quanh đường thẳng tham chiếu $e = 0$ và đường xu hướng (thường là đường mượt màu đỏ) phải gần như nằm ngang phẳng.

Nếu các điểm tạo thành một hình vòng cung (parabol), mô hình đang vi phạm tính tuyến tính (bỏ sót các biến bậc cao). Nếu độ phân tán mở rộng hoặc thu hẹp theo hình cái phễu, phương sai sai số đang bị thay đổi.

1.9.2. Đồ thị Normal Q-Q

Kiểm tra giả thiết phần dư theo phân phối chuẩn $\varepsilon \sim \mathcal{N}(0, \sigma^2)$. Đối chiếu các phân vị thực nghiệm đã chuẩn hóa của phần dư mẫu trên trục tung với phân vị lý thuyết của phân phối chuẩn

tắc trên trục hoành.




Hình 1.2: Đồ thị Normal Q-Q

Tất cả các điểm phần dư phải nằm bám sát hoặc trùng khít lên đường thẳng chéo 45° tham chiếu. Điều này khẳng định các kiểm định thống kê (t -test, F -test) và khoảng tin cậy sau đó hoàn toàn có hiệu lực.

Nếu các điểm ở hai đầu mút uốn cong lệch hẳn khỏi đường thẳng (dạng chữ S hoặc chữ U), phần dư đang rơi vào tình trạng đuôi dày (heavy-tailed) hoặc phân phối bị lệch (skewed), không chuẩn.

1.9.3. Đồ thị Scale - Location

Kiểm tra chuyên sâu giả thiết phương sai sai số đồng đều (Homoscedasticity), loại bỏ sự phụ thuộc vào dấu (âm/dương) của phần dư. Trục hoành biểu diễn giá trị dự báo $\hat{y}_i$, trục tung biểu diễn căn bậc hai của giá trị tuyệt đối phần dư đã chuẩn hóa.




Hình 1.3: Đồ thị Scale - Location

1.9.4. Đồ thị khoảng cách Cook

Xác định các điểm dữ liệu dị biệt có sức ảnh hưởng lớn (Influential Points), tức là những điểm mà nếu xóa chúng đi sẽ làm thay đổi cấu trúc toàn bộ hệ số hồi quy một cách nghiêm trọng.

Trục hoành biểu diễn chỉ số (index) của từng quan sát trong bộ dữ liệu, trục tung biểu diễn giá trị khoảng cách Cook (D_i) của quan sát đó. Công thức toán học:

$$D_i = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(-i)})^2}{(p+1)\hat{\sigma}^2}$$



Hình 1.4: Đồ thị khoảng cách Cook

Tất cả các điểm dữ liệu đều có khoảng cách Cook nhỏ và tương đương nhau, không có điểm nào vượt trội.

Điểm nào có giá trị D_i vượt quá ngưỡng quy ước (thường chọn ngưỡng phổ biến là $D_i > 4/n$ hoặc $D_i > 1$) là điểm có sức ảnh hưởng cực đoan. Nhóm nghiên cứu cần kiểm tra lại các quan sát này xem có phải lỗi nhập liệu (outliers) hay không để cân nhắc loại bỏ hoặc áp dụng hồi quy bền vững (Robust Regression).

1.10. Phương Pháp Kiểm Định Chéo

Trong bài toán Data Fitting, một mô hình đạt tổng bình phương phần dư rất nhỏ trên tập dữ liệu chưa chắc đã là mô hình tốt, vì nó có thể bị overfitting, tức là mô hình đã quen với nhiễu của tập dữ liệu cũ mà không thể dự đoán tốt trên các tập dữ liệu mới.

Do đó, để đánh giá một cách khách quan năng lực tổng quát hóa của một mô hình, ta sử dụng phương pháp kiểm định chéo (Cross-Validation - CV).

Quy trình thực hiện thuật toán được thực hiện qua các bước sau:

1. Phân chia dữ liệu: Toàn bộ tập dữ liệu gốc $\mathcal{D}$ gồm n mẫu được xáo trộn ngẫu nhiên và chia thành k phần (folds) có kích thước bằng nhau hoặc xấp xỉ bằng nhau: $\mathcal{D}_1, \mathcal{D}_2, \dots, \mathcal{D}_k$.
2. Lặp huấn luyện và kiểm thử: Quá trình được lặp lại đúng k lần (với mỗi $i = 1, 2, \dots, k$):
 - Sử dụng phần $\mathcal{D}_i$ làm Tập kiểm thử (Validation set / Test fold).
 - Sử dụng hợp của $k - 1$ phần còn lại làm Tập huấn luyện (Training set) để ước lượng vector tham số $\hat{\beta}^{(-i)}$.
 - Áp dụng nghiệm $\hat{\beta}^{(-i)}$ vừa học để dự báo trên tập $\mathcal{D}_i$ và tính toán sai số (ví dụ: MSE_i hoặc $RMSE_i$).
3. Tổng hợp kết quả: Sai số kiểm định chéo tổng thể (CV Error) là trung bình cộng của các sai số thành phần thu được từ k lần lặp:

$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i$$

Để kết luận mô hình Data Fitting có hoạt động tốt và ổn định hay không, nhóm nghiên cứu thực hiện đối chiếu song song giữa Train Error (Sai số huấn luyện) và CV Score (Sai số kiểm định chéo):

- Mô hình Tối ưu (Good Fit): Cả Train Error và CV Score đều ở mức thấp hợp lý và có giá trị xấp xỉ tương đương nhau. Điều này chứng tỏ mô hình vừa học tốt quy luật, vừa có khả năng tổng quát hóa cao trên dữ liệu mới.
- Mô hình Quá khớp (Overfitting): Train Error rất thấp nhưng CV Score lại cao rõ rệt. Khoảng cách (gap) giữa hai giá trị này càng lớn thì mức độ quá khớp càng nghiêm trọng.
- Mô hình Dưới khớp (Underfitting): Cả Train Error và CV Score đều cao và không thể giảm thêm dù thay đổi cách chia fold.

1.11. Phương Pháp Mô Phỏng Monte Carlo

1.11.1. Nguyên lý áp dụng

Để nghiệm đúng định lý Gauss-Markov bằng mô phỏng, phương pháp Monte Carlo thiết lập hai hệ quy chiếu nghiêm ngặt:

- Kiểm chứng Tính không chệch: Nếu một toán tử ước lượng là không chệch, thì khi ta lấy trung bình cộng tất cả các vector nghiệm thu được qua B lần mô phỏng, giá trị kỳ vọng mẫu đó phải hội tụ chính xác về giá trị thực tế ban đầu của tham số:

$$\bar{\beta} = \frac{1}{B} \sum_{b=1}^B \hat{\beta}^{(b)} \approx \beta_{true}$$

Monte Carlo sẽ chạy song song OLS và các thuật toán ước lượng tuyến tính khác để chứng minh chúng đều cùng thỏa mãn thuộc tính không chệch này.

- Kiểm chứng Phương sai tối thiểu: Sau khi đã xác nhận các toán tử so sánh đều không chệch, Monte Carlo sẽ tiến hành đo lường biên độ dao động (phương sai mẫu) của từng hệ số qua hàng ngàn lượt lặp.

Lý thuyết Gauss-Markov sẽ được chứng nghiệm nếu phương sai của OLS luôn bé hơn bất kỳ một phương sai của ước lượng tuyến tính không chệch nào khác

$$\text{Var}(\hat{\beta}_{OLS}) < \text{Var}(\hat{\beta}_{Other})$$

1.11.2. Ý nghĩa đặc biệt của mô phỏng Monte Carlo

Giá trị cốt lõi của phương pháp mô phỏng Monte Carlo nằm ở khả năng nghiệm chứng tính độc lập của định lý Gauss-Markov đối với giả thiết phân phối chuẩn.

Về mặt đại số, định lý Gauss-Markov thiết lập tính không chệch tốt nhất dựa trên các điều kiện của vector sai số ngẫu nhiên, hoàn toàn không phụ thuộc vào điều kiện phân phối chuẩn. Tuy nhiên, mô phỏng Monte Carlo vẫn cho thấy OLS vẫn duy trì được phương sai nhỏ nhất, khẳng định tính đúng đắn của định lý Gauss-Markov.

1.12. Kết Quả Thực Nghiệm và Minh Họa Số Liệu

1.12.1. Kiểm chứng tính chất toán học của ma trận chiếu

Nhóm tiến hành khởi tạo ma trận thiết kế $\mathbf{X}$ ngẫu nhiên và tính toán ma trận chiếu $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$. Các sai số số học được đo lường thông qua chuẩn Frobenius ($\|\cdot\|_F$) để đánh giá các tính chất lý thuyết:

- Tính chất đối xứng: Sai số đối xứng tính toán được là $\|\mathbf{H} - \mathbf{H}^T\|_F \approx 0$ (giá trị thực tế trên máy tính đạt bậc sai số máy $< 10^{-16}$). Kết quả này xác nhận toán tử chiếu hoạt động trên một cấu trúc trực giao hoàn hảo.
- Tính chất lũy đẳng: Sai số lũy đẳng $\|\mathbf{H}^2 - \mathbf{H}\|_F \approx 0$. Điều này chứng minh thực nghiệm rằng việc áp dụng toán tử chiếu nhiều lần lên vector đã chiếu không làm thay đổi vị trí không gian của nó.
- Giá trị vết ma trận (Trace): Giá trị vết tính được là $\text{trace}(\mathbf{H}) = 3.0$. Kết quả này hoàn toàn trùng khớp với lý thuyết vì ma trận thiết kế gồm 2 biến độc lập và 1 hệ số chặn ($p + 1 = 3$), tương ứng với số bậc tự do hay số chiều của không gian con dự báo.

1.12.2. Kết quả ước lượng OLS và phân tích ý nghĩa thống kê

Sử dụng bộ dữ liệu giả lập gồm biến mục tiêu y và hai biến báo cáo β_1 , β_2 và β_3 , thuật toán OLS tự xây dựng trả về các thông số ước lượng chi tiết:


Hệ số	β_{true}	$\hat{\beta}$	SE	t-stat	p-value	CI 95%
Intercept (β_0)	10.000	10.056	0.0455	221.142	8.506×10^{-132}	[9.966, 10.147]
Predictor 1 (β_1)	5.000	4.961	0.0546	90.854	6.596×10^{-95}	[4.853, 5.070]
Predictor 2 (β_2)	0.010	-0.015	0.0460	-0.326	7.455×10^{-1}	[-0.106, 0.076]
Predictor 3 (β_3)	-2.300	-2.354	0.0407	-57.783	2.192×10^{-76}	[-2.435, -2.273]

Bảng 1.2: Kết quả ước lượng các hệ số hồi quy của mô hình

Nhận xét kết quả:

- Mã nguồn kiểm định chính xác vai trò của β_1 và β_3 với giá trị p-value cực kỳ nhỏ (< 0.05) và khoảng tin cậy tách biệt khỏi điểm 0. Khẳng định hai biến trên có tác động mạng và mang ý nghĩa thống kê.
- Đối với β_2 được thiết lập thực tế hệ số thực tế rất nhỏ $\beta_2 = 0.01$, mã nguồn trả về giá trị p-value rất lớn ($0.7455 > 0.05$) và khoảng tin cậy giữa điểm 0. Chứng tỏ rằng mã nguồn đã loại bỏ được những biến số không mang thông tin giải thích cho mô hình.

1.12.3. Nhận xét về các đồ thị phân tích phần dư



Hình 1.5: Tổng hợp các đồ thị phân tích phần dư

Đồ thị Residuals vs Fitted

Các điểm dữ liệu không phân tán hỗn loạn mà tách thành nhiều đường sọc chéo song song có độ dốc âm, phân bố đối xứng qua đường trung bình $e = 0$ và tập trung mật độ dày đặc nhất ở dải giá trị dự báo từ 0.5 đến 1.5.

Nhận xét: Các điểm phân bố tương đối đối xứng quanh trục hoành và không tạo thành dạng đường cong Parabol, cho thấy giả thiết về tính tuyến tính của mô hình được thỏa mãn. Hiện tượng các đường sọc song song xuất hiện là do bản chất dữ liệu giả lập (synthetic data) có các biến độc lập hoặc biến mục tiêu nhận các giá trị rời rạc từng phần, khiến phần dư phụ thuộc tuyến tính vào giá trị khớp mẫu $\hat{y}$.

Đồ thị Normal Q-Q

Toàn bộ các điểm phần dư mẫu nằm trùng khớp rõ ràng, bám sát theo đường thẳng chéo 45° tham chiếu từ đầu mút trái sang đầu mút phải. Không xuất hiện hiện tượng uốn cong hay lệch quỹ đạo ở hai phía đuôi.

Nhận xét: Kết quả cho thấy giả thiết phần dư tuân theo phân phối chuẩn ($\varepsilon \sim \mathcal{N}(0, \sigma^2)$) được thỏa mãn hoàn toàn. Điều này khẳng định tất cả các suy diễn thống kê ở mục trước (giá trị kiểm định t , F , p -value và khoảng tin cậy 95%) đều đạt độ chính xác và tin cậy tối đa.

Đồ thị Scale-Location Plot

Các giá trị căn bậc hai phần dư chuẩn hóa phân bố tương đối đồng đều theo các giá trị dự báo $\hat{y}$ và không xuất hiện xu hướng mở rộng hay thu hẹp rõ rệt theo hình phễu.

Nhận xét: Kết quả cho thấy chưa có dấu hiệu phương sai thay đổi theo giá trị dự báo. Do đó giả thiết GM4 về phương sai nhiều thuần nhất (homoscedasticity) được xem là thỏa mãn.

Đồ thị Cook's Distance

Trục tung hiển thị khoảng cách Cook (D_i) của các quan sát có giá trị cực kỳ bé, điểm cao nhất cũng chỉ đạt mức $D_i \approx 0.024$. Toàn bộ các điểm còn lại đều nằm phẳng dưới đáy sát mức 0.00.

Nhận xét: Theo lý thuyết, ngưỡng cân nhắc điểm ảnh hưởng có thể tính bằng $4/n \approx 0.008$. Mặc dù có một vài quan sát nổi trội và vượt nhẹ qua ngưỡng này, nhưng xét theo tiêu chuẩn phổ biến của Cook (ngưỡng 0.5 hoặc 1.0), toàn bộ các điểm dữ liệu đều nằm sâu phía dưới. Vì vậy, có

thể kết luận không có quan sát nào có ảnh hưởng nguy hiểm kết quả hồi quy.

1.12.4. Kiểm chứng định lý Gauss-Markov bằng mô phỏng Monte Carlo

Để chứng minh cho đặc tính tuyến tính không chệch tốt nhất (BLUE) của OLS một cách trực quan, tiến hành mô phỏng Monte Carlo với số lần $B = 1000$. Nghiệm OLS được so sánh trực tiếp với nghiệm của phương pháp bình phương tối thiểu nhưng với trọng số ngẫu nhiên.

Nhận xét

Về tính không chệch: Trị trung bình thực nghiệm (kỳ vọng mẫu) của các hệ số hồi quy thu được từ cả hai phương pháp OLS và WLS sau 1000 lần lặp đều hội tụ sát về giá trị thực tế ban đầu của tham số β với sai số cực nhỏ ($< 10^{-3}$). Thực nghiệm xác nhận cả hai đều là ước lượng không chệch.

Hệ số	$\beta_{\text{thực}}$	$E[\hat{\beta}_{\text{OLS}}]$	$E[\hat{\beta}_{\text{Other}}]$	$ \text{bias}_{\text{OLS}} $	$ \text{bias}_{\text{Other}} $
β_0	5.000	5.0037	4.9993	0.003735	0.000735
β_1	2.500	2.4992	2.5052	0.000769	0.005196
β_2	-1.500	-1.4962	-1.4928	0.003827	0.007212


Bảng 1.3: So sánh kỳ vọng và trị tuyệt đối sai số chệch (Bias) giữa các phương pháp ước lượng

Về phương sai nhỏ nhất: Quan sát đồ thị mật độ phân bố thực nghiệm, đường cong phân phối xác suất của ước lượng OLS (màu xanh) luôn có biên độ hẹp hơn và cao dốc hơn so với đường cong của phương pháp WLS ngẫu nhiên (màu cam). Đo lường thống kê số học khẳng định phương sai của OLS luôn nhỏ hơn tuyệt đối ($\text{Var}(\hat{\beta}_{\text{OLS}}) < \text{Var}(\hat{\beta}_{\text{WLS-random}})$) trên toàn bộ tất cả các hệ số.

Hệ số	$\text{Var}(\hat{\beta}_{\text{OLS}})$	$\text{Var}(\hat{\beta}_{\text{Other}})$	Tỷ lệ Other/OLS
β_0	0.046291	0.060340	1.30×
β_1	0.038514	0.051737	1.34×
β_2	0.046439	0.062810	1.35×

Bảng 1.4: So sánh phương sai (Variance) và tỷ lệ hiệu quả giữa các phương pháp ước lượng

Monte Carlo (B=1000) — Kiểm chứng Định lý Gauss-Markov:
OLS (xanh) có phương sai nhỏ hơn WLS ngẫu nhiên (cam)



Hình 1.6: Kết quả mô phỏng Monte Carlo

CHƯƠNG 2

Ứng Dụng Thực Tế

2.1. Giới Thiệu Bộ Dữ Liệu và Bài Toán

2.1.1. Giới thiệu bộ dữ liệu

Đồ án tiến hành phân tích và xây dựng mô hình đánh giá dựa trên bộ dữ liệu ảnh cộng hưởng từ não bộ theo dõi dọc (Longitudinal MRI) thuộc dự án OASIS-2 do đại học Washington cung cấp.

Bộ dữ liệu chứa thông tin sinh học và nhân khẩu học từ 373 lượt khám đến từ 150 bệnh nhân khác nhau trong độ tuổi từ 60 đến 96.

2.1.2. Mục tiêu và ý nghĩa thực tế

- Mục tiêu: Xây dựng mô hình cơ sở để dự đoán mức độ suy giảm nhận thức của bệnh nhân thông qua chỉ số đánh giá trạng thái tâm thần tối thiểu MMSE (Mini-Mental State Examination).
- Biến dự đoán chủ đạo: Thể tích não bộ đã chuẩn hóa nWBV (Normalized Whole Brain Volume) đại diện cho mức độ teo mô não lâm sàng cùng với một số yếu tố nhân khẩu học, kinh tế - xã hội khác.
- Lý do lựa chọn: Bộ dữ liệu sở hữu cấu trúc theo dõi dọc quý giá (cho phép đánh giá quá trình thay đổi của bệnh thông qua mốc thời gian *Visit*, *MR Delay*), tỷ lệ dữ liệu bị khuyết ở mức độ thấp và mang ý nghĩa thực tiễn trong việc hỗ trợ chẩn đoán và tiên lượng sớm hội chứng sa sút trí tuệ (Alzheimer).

2.1.3. Đặc tả của các thuộc tính quan trọng

Thuộc tính	Loại dữ liệu	Tính chất	Dữ liệu khuyết	Vai trò	Mô tả
Subject_ID	Categorical	N/A	0 (0%)	Index/Group	Mã định danh duy nhất của từng bệnh nhân.
MMSE	Numerical	Continuous*	2 (0.5%)	Target	Điểm nhận thức (0-30). Điểm càng thấp biểu hiện suy giảm càng nặng.
Age	Numerical	Continuous	0 (0%)	Feature	Độ tuổi của bệnh nhân tại thời điểm khám.
nWBV	Numerical	Continuous	0 (0%)	Feature	Thể tích toàn bộ não đã chuẩn hóa.
eTIV	Numerical	Continuous	0 (0%)	Feature	Ước tính tổng thể tích hộp sọ.
SES	Ordinal	Discrete	19 (5.09%)	Feature	Chỉ số Kinh tế - Xã hội (Thang đo từ 1 - Cao nhất đến 5 - Thấp nhất).

Bảng 2.1: Đặc trưng dữ liệu của các thuộc tính quan trọng

Lưu ý: Chỉ số MMSE dựa trên lý thuyết là biến rời rạc với giá trị từ 0 đến 30, tuy nhiên trong nguyên cứu hồi quy lâm sàng và y sinh, chỉ số trên được chấp nhận rộng rãi như một biến liên tục.

2.2. Khảo Sát Dữ Liệu


2.2.1. Kiểm tra chất lượng dữ liệu ban đầu

Dữ liệu trùng lặp

Hệ thống ghi nhận không có dòng nào bị trùng lặp hoàn toàn. Các mã MRI ID đều mang tính duy nhất. Dữ liệu mang tính toàn vẹn về mặt định danh tốt, không cần phải thực hiện thao tác loại bỏ trùng lặp.

Dữ liệu bị khuyết

Hệ thống ghi nhận một số dòng bị thiếu thông tin tại các hai thuộc tính SES khuyết 19 dòng ($\sim 5.09\%$) và MMSE khuyết 2 dòng ($\sim 0.54\%$). Các thuộc tính còn lại không bị khuyết.



Hình 2.1: Heatmap dữ liệu bị khuyết


2.2.2. Bảng thống kê mô tả

STT	Ký hiệu biến	Giá trị trung bình (Mean)	Độ lệch chuẩn (Std. Dev)	Giá trị nhỏ nhất (Min)	Trung vị (Median)	Giá trị lớn nhất (Max)
1	Group	<i>N/A (Định danh)</i>	<i>N/A</i>	<i>N/A</i>	<i>N/A</i>	<i>N/A</i>
2	Visit	1.88	0.92	1.00	2.00	5.00
3	MR Delay	595.10	443.19	0.00	552.00	2639.00
4	Age	77.01	7.64	60.00	77.00	98.00
5	EDUC	14.60	2.88	6.00	15.00	23.00
6	SES	2.46	1.13	1.00	2.00	5.00
7	MMSE	27.34	3.68	4.00	29.00	30.00
8	CDR	0.29	0.37	0.00	0.00	2.00
9	eTIV	1488.12	176.13	1106.00	1475.00	2004.00
10	nWBV	0.73	0.04	0.64	0.73	0.84
11	ASF	1.20	0.14	0.88	1.19	1.59

Bảng 2.2: Thống kê mô tả các biến số

2.2.3. Khảo sát tương quan và Phân phối

Khảo sát tương quan



Hình 2.2: Heatmap tương quan giữa các hệ số

Mối tương quan với biến mục tiêu MMSE:

- nWBV ($r = 0.34$) có mối tương quan thuận mạnh nhất với biến mục tiêu, chứng minh giả thiết y khoa thể tích của toàn bộ não càng lớn thì duy trì khả năng nhận thức càng cao.
- EDUC ($r = 0.18$) có mối tương quan thuận cao nhì với biến mục tiêu. Điều này cho thấy bệnh nhân có số năm học thức càng cao thì tốc độ suy giảm trí tuệ càng thấp nhờ vào quá trình học tập có vai trò dự trữ nhận thức.
- SES ($r = -0.15$) có mối tương quan nghịch nhẹ so với biến mục tiêu. Do chỉ số kinh tế - xã hội có thang đo ngược (1 - cao nhất, 5 - thấp nhất), những người có vị thế xã hội càng cao thì thường sở hữu mức độ minh mẫn tốt hơn.

Ngoài ra, giữa hai biến **eTIV** và **ASF** có mối tương quan nghịch cực kỳ cao, gần như tuyệt đối với $r = -0.99$. Mối quan hệ trên báo hiệu nguy cơ cực kỳ cao xảy ra hiện tượng đa cộng tuyến nếu cả hai cùng được đưa vào quá trình xử lý.


Một số ý nghĩa của các mối quan hệ khác:

- **EDUC** và **SES** cho thấy tương quan nghịch khá cao với $r = -0.72$. Ta có thể thấy được số năm đi học càng nhiều sẽ tương ứng với vị thế kinh tế xã hội càng cao, phản ánh đúng logic thực tế.
- **Is_Male** và **eTIV** cho thấy tương quan thuận mạnh với $r = 0.57$. Điều đó chỉ ra rằng, bệnh nhân nam thường có xu hướng thể tích hộp sọ lớn hơn đáng kể so với nữ. Tuy nhiên **Is_Male** lại không cho thấy mối tương quan trực tiếp nào với **MMSE** với $r = -0.05$.

Phân phối các biến



Hình 2.3: Phân phối của các biến (Histogram)



Hình 2.4: Phân phối của các biến (Boxplot)

Biến **MMSE** có xu hướng bị lệch phải, phần lớn tập trung ở mức điểm từ 26 đến 30 thuộc nhóm bình thường hoặc chỉ suy giảm trí tuệ ở mức nhẹ. Các biến **nWBV** và **eTIV** tuân theo phân phối tương đối tiệm cận chuẩn.

2.3. Tiền Xử Lý Dữ Liệu

2.3.1. Chọn lọc biến cho quá trình xử lý

Để đảm bảo tính nghiêm ngặt về mặt toán học trong quá trình xây dựng các mô hình, các biến sau sẽ được loại bỏ khỏi quá trình huấn luyện:

- **Hand:** Tất cả các giá trị đều là R (các bệnh nhân đều thuận tay phải) nên được loại bỏ vì không mang lại giá trị phân tách thông tin.
- **Subject ID, MRI ID:** Các mã định danh thuần túy, không mang tính chất vật lý hay y học lên nhận thức.
- **Group, CDR:** Các biến trên phản ánh trực tiếp kết luận lâm sàng hoặc phân loại mức độ sa sút trí tuệ vốn là kết luận dựa trên **MMSE**. Nếu sử dụng sẽ gây nên hiện tượng rò rỉ đích (Target Leakage) trầm trọng.
- **Visit, MR Delay:** Các biến thể hiện thời gian của cấu trúc theo dõi dọc, không trực tiếp

định lượng mức độ suy giảm sinh học tại một thời điểm độc lập.


- ASF: Loại bỏ vì có mối tương quan đa cộng tuyến hoàn hảo với biến eTIV.

2.3.2. Xử lý dữ liệu khuyết thiếu

Qua quá trình phân tích, biến SES (Chỉ số kinh tế - xã hội) có mối tương quan cao với biến EDUC ($r = -0.44$). Điều đó chỉ ra rằng, một bệnh nhân lựa chọn bỏ trống các thông tin về vị thế kinh tế - xã hội không phải là ngẫu nhiên hoàn toàn mà là do nền tảng giáo dục của họ. Những đối tượng có số năm đi học đặc thù thường có xu hướng bỏ trống khai báo vị thế xã hội.

Do đó mà biến SES bị khuyết thiếu ngẫu nhiên có điều kiện (Missing At Random - MAR).

Phương pháp xử lý: Điền khuyết dựa trên phân nhóm **Group-by Median** theo EDUC. Giá trị bị thiếu của SES sẽ được thay thế bằng giá trị trung vị của SES trích xuất từ nhóm các bệnh nhân có cùng số năm đi học. Phương pháp này giúp bảo toàn hình dáng phân phối của dữ liệu, tránh làm lệch phân phối so với việc sử dụng trung vị tổng thể.



Hình 2.5: Phân phối biến SES trước và sau điền khuyết

Đối với các giá trị khuyết của biến MMSE, vì chỉ chiếm 2 dòng trên tổng số 373 dòng, tương đương với 0.53% nên ta tiến hành loại bỏ trực tiếp 2 dòng trên (Listwise Deletion) để tránh gây nhiễu cho nhãn huấn luyện.

Không sử dụng phương pháp gán giá trị nào đối với MMSE vì nó là biến phụ thuộc nên việc gán một giá trị điền khuyết sẽ tạo ra dữ liệu giả lập, làm sai lệch phân phối thực tế của sai số ngẫu nhiên.

2.3.3. Phân tách dữ liệu chống rò rỉ

Do dữ liệu có tính chất theo dõi dọc (Longitudinal Data), một bệnh nhân có thể xuất hiện nhiều lần tại các lượt khám bệnh khác nhau.

Nếu sử dụng các phương pháp tách ngẫu nhiên thông thường như `train_test_split` thì các lượt khám của cùng một bệnh nhân sẽ bị phân tán vào cả tập huấn luyện và tập kiểm thử. Điều này sẽ vi phạm nghiêm trọng đến giả định độc lập dữ liệu và gây ra hiện tượng rò rỉ dữ liệu (Data Leakage), khiến mô hình có kết quả tốt trên tập kiểm thử nhưng mất khả năng tổng quát hóa trên bệnh nhân mới hoàn toàn.

Sử dụng chiến lược **GroupShuffleSplit** dựa trên trường khóa Subject ID. Kỹ thuật này đảm bảo rằng toàn bộ các bản ghi thuộc về cùng một bệnh nhân cụ thể sẽ chỉ nằm duy nhất ở tập Train hoặc tập Test, cô lập hoàn toàn định danh giữa hai tập dữ liệu.

2.3.4. Kiểm tra đa cộng tuyến qua VIF

Biến độc lập	Hệ số VIF
nWBV	1.383201
Age	1.370726
EDUC	2.077066
SES	2.083056

Bảng 2.3: Hệ số phóng đại phương sai (VIF) của các biến độc lập

Bảng chỉ số VIF xác nhận các hệ số phóng đại phương sai của tất cả các biến giữ lại đều nằm trong ngưỡng an toàn dưới 5. Hiện tượng đa cộng tuyến nghiêm trọng đã bị loại bỏ hoàn toàn sau khi loại bớt biến dư thừa (ASF).

2.4. Xây Dựng và So Sánh Các Mô Hình

2.4.1. Mô hình OLS Cơ Bản

Mô hình được xây dựng dựa trên phương pháp OLS thông thường. Dữ liệu đầu vào bao gồm các biến độc lập được chọn ban đầu sau khi đã loại bỏ một số biến gây rò rỉ mục tiêu. Mô hình không sử dụng chuẩn hóa nhằm lập mốc tham chiếu cho các mô hình phức tạp hơn.

Feature	Coefficient	Std. Error	t-stat	p-value	95% CI
nWBV	58.49	6.18	9.46	1.11×10^{-18}	[46.32, 70.66]
Age	0.18	0.03	6.05	4.46×10^{-9}	[0.12, 0.24]
EDUC	0.13	0.10	1.33	0.18	[-0.06, 0.33]
SES	-0.49	0.25	-2.00	0.05	[-0.98, -0.01]

Bảng 2.4: OLS Cơ Bản - Hệ số hồi quy tuyến tính của các biến

Mô hình	MAE	RMSE	R2_test
OLS Baseline	2.301759	2.973812	-0.133835

Bảng 2.5: OLS Cơ Bản - Kết quả đánh giá

Nhận xét hệ số hồi quy:

- **nWBV** mang giá trị dương và có ý nghĩa thống kê cực kỳ cao. Chứng minh rằng thể tích mô não tỷ lệ thuận cực kỳ cao với điểm số nhận thức MMSE; khi não bộ có dấu hiệu teo điểm số MMSE sẽ giảm tuyến tính theo một tỷ lệ nhất định.
- **Age** ban đầu có sự mâu thuẫn vì tuổi cao thường đi kèm suy giảm nhận thức. Tuy nhiên Age chỉ phản ánh hiệu ứng có điều kiện sau khi đã kiểm soát **nWBV** - những bệnh nhân lớn tuổi trong giai đoạn nghiên cứu là những người khỏe mạnh hơn.
- **SES** có p-value vừa đủ vượt ngưỡng $\alpha = 0.05$. Tuy nhiên với khoảng tin cậy gần chạm 0 cho thấy ý nghĩa thống kê không mạnh.

- EDUC không mang ý nghĩa thống kê sau khi đã kiểm soát các biến còn lại. Số năm học vẫn không đóng góp thêm thông tin dự báo độc lập cho MMSE.

2.4.2. Mô hình OLS Chọn Biến

Mô hình OLS chọn biến áp dụng quy trình hai bước. Đầu tiên sử dụng VIF để phát hiện đa cộng tuyến - kết quả tại bảng 1.3 cho thấy không có biến nào vượt ngưỡng $VIF = 5$ nên không có biến nào loại ở bước này. Tiếp theo, xem xét các biến nào có p-value vượt ngưỡng từ kết quả của OLS Cơ bản để loại bỏ vì không mang ý nghĩa thống kê.

Ở mục trên, biến EDUC có $p = 0.183 > 0.05$ và khoảng tin cậy chưa 0 nên biến trên không đóng góp thêm thông tin dự báo độc lập nào cho MMSE nên EDUC bị loại khỏi mô hình này.

Feature	Coefficient	Std. Error	t-stat	p-value	95% CI
nWBV	59.27	6.16	9.62	3.40×10^{-19}	[47.14, 71.40]
Age	0.18	0.03	6.05	4.35×10^{-9}	[0.12, 0.24]
SES	-0.73	0.17	-4.25	2.83×10^{-5}	[-1.06, -0.39]

Bảng 2.6: OLS Chọn Biến - Hệ số hồi quy tuyến tính của các biến

Mô hình	MAE	RMSE	R2_test
OLS Chọn Biến	2.308602	3.040419	-0.185195

Bảng 2.7: OLS Chọn Biến - Kết quả đánh giá

So sánh với OLS Cơ Bản:

- Sau khi loại bỏ biến EDUC, các biến còn lại đều mang ý nghĩa thống kê với p-value hợp lệ. Hệ số của SES thay đổi đáng kể so với OLS Cơ Bản từ -0.49 ($p = 0.047$) lên -0.73 ($p = 2.83 \times 10^{-5}$) và khoảng tin cậy thu hẹp lại. Do đó mà trong mô hình cơ bản, EDUC đang che khuất một phần tác động thực sự của SES lên MMSE.
- Về mặt hiệu năng dự báo, OLS Chọn Biến không ghi nhận quá nhiều thay đổi so với OLS Cơ Bản. Giá trị R^2 âm cho thấy cả hai mô hình đều dự báo kém hơn mô hình trung bình

đơn giản trên tập test. Cho thấy giới hạn của hồi quy tuyến tính trên tập dữ liệu có phân phối lệch mạnh.


2.4.3. Mô hình Hồi Quy Ridge

Mô hình hồi quy Ridge bổ sung số hạng phạt L_2 vào hàm mất mát để kiểm soát độ lớn của hệ số, giảm phương sai mô hình nhưng đổi lại sẽ làm giảm đi tính không chệch của mô hình. Việc đánh đổi tính chệch và phương sai là cần thiết đối với dữ liệu có độ nhiễu cao.

Đường cong sai số kiểm định chéo (CV error curve) là đồ thị biểu diễn mối quan hệ giữa giá trị của siêu tham số và sai số kiểm định chéo trung bình.

Khi thay đổi λ từ rất nhỏ đến rất lớn:

- Nếu λ quá nhỏ, mô hình dần trở thành mô hình OLS. Mô hình rất linh hoạt, dễ bị overfitting. Sai số trên tập test thấp nhưng CV error cao.
- Nếu λ quá lớn, các hệ số bị phạt quá nặng và tiến về 0. Mô hình trở nên rất đơn giản, dẫn đến bị underfitting. Cả sai số huấn luyện và CV error đều rất cao.
- Nếu λ vừa đủ, mô hình có sự cân bằng tốt nhất giữa độ chệch và phương sai. Khi đó, CV error đạt giá trị nhỏ nhất.



Hình 2.6: CV Error Curve

Siêu tham số λ được chọn qua k-fold cross-validation với $k = 5$ trên tập test. Trục hoành gồm 100 giá trị phân bố trên thang log từ 10^{-3} đến 10^3 . CV MSE đạt giá trị cực tiểu tại $\lambda = 6.5793$.

Mô hình	MAE	RMSE	R2_test
Ridge	2.289937	2.943182	-0.110598

Bảng 2.8: Ridge - Kết quả đánh giá

Nhận xét:

- So với hai mô hình trước, Ridge cho thấy sự cải thiện nhất quán trên cả ba chỉ số MAE, RMSE và R^2 . Chứng tỏ rằng việc phạt số hạng L_2 đã có tác dụng kiểm soát phương sai của hệ số, giúp việc tổng quát hóa trở nên tốt hơn trên tập test.
- Giá trị R^2 vẫn bị âm cho thấy Ridge vẫn chưa vượt qua được mô hình trung bình trên tập test. Mô hình chỉ giải quyết được vấn đề phương sai của hệ số thông qua việc thu hẹp nhưng vẫn bị ràng buộc bởi giả thiết tuyến tính trong khi mô hình có cấu trúc phi tuyến nhất định.


2.4.4. Mô hình Hồi Quy Kernel Ridge

Dựa trên kết quả phân tích của các mô hình hồi quy tuyến tính, mô hình hồi quy Kernel Ridge được thử nghiệm nhằm kiểm tra giả thuyết giữa các biến có thành phần phi tuyến hay không. Mô hình sử dụng hàm kernel RBF:

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$$

thay thế tích vô hướng thông thường trong không gian đặc trưng gốc, cho phép mô hình nắm bắt các quan hệ phi tuyến thông qua kernel trick mà không cần tường minh xây dựng đặc trưng bậc cao.

Để lựa chọn tham số α và γ phù hợp, nhóm đã tiến hành Grid Search kết hợp CV với $k = 5$ trên lưới tìm kiếm $\alpha \in \{0.01, 0.1, 0.5, 1.0, 5.0, 10.0\}$ và $\gamma \in \{0.001, 0.01, 0.1, 0.5, 1.0\}$. Cặp siêu tham số tối ưu (α, γ) thu được là $\alpha = 0.01$ và $\gamma = 0.1$.



Hình 2.7: Kernel Ridge - CV MSE theo lưới

Mô hình	MAE	RMSE	R2_test
Kernel Ridge	2.304598	3.285159	-0.383705

Bảng 2.9: Kernel Ridge - Kết quả đánh giá

Nhận xét:

- Kernel Ridge cho hiệu năng thấp hơn cả ba chỉ số với $R^2 = -0.384$ so với $R^2 = -0.111$ của Ridge.
- Với 4 biến đặc trưng, không gian gốc đã đủ đơn giản để Ridge xử lý hiệu quả. RBF kernel ánh xạ dữ liệu vào không gian vô hạn chiều nhưng tính phi tuyến trong 4 biến đã chọn không đủ để kernel khai thác, khi đó sẽ tăng nguy cơ overfit trên tập train nhỏ.
- Với 240 quan sát trong tập train, giá trị α chưa đủ ổn định để ma trận Gram $K \in \mathbb{R}^{240 \times 240}$.
- Phân phối của MMSE bị lệch mạnh về vùng điểm cao (26-30) khiến các mô hình đều gặp khó khăn trong việc học pattern ở vùng điểm thấp - nơi có ít quan sát nhưng biến động lớn.

2.4.5. Kết luận mô hình tối ưu nhất

Model	MAE	RMSE	R2_test
OLS Baseline (Nguyên bản)	2.3018	2.9738	-0.1338
OLS Baseline (Khử VIF)	2.3086	3.0404	-0.1852
Ridge Regression ($\lambda = 6.5793$)	2.2899	2.9432	-0.1106
Kernel Ridge ($\alpha = 0.01, \gamma = 0.1$)	2.3046	3.2852	-0.3837

Bảng 2.10: Bảng so sánh tổng hợp kết quả giữa các mô hình

Dựa trên bảng so sánh, mô hình hồi quy Ridge là mô hình tốt nhất trong bộ thử nghiệm với $MAE = 2.290$, $RMSE = 2.943$ và $R^2 = -0.111$ - cải thiện tổng thể so với các mô hình còn lại.


Mặc dù giá trị R^2 âm ở trên tất cả các mô hình cho thấy không mô hình nào vượt được mốc dự báo trung bình đơn giản trên tập test, Ridge vẫn được chọn là mô hình tốt nhất vì hai lý do.

- Về mặt thống kê, số hạng phạt L_2 để kiểm soát hiệu quả phương sai của tham số, giảm RMSE xuống còn 3.4% so với OLS.
- Về mặt ứng dụng lâm sàng, Ridge duy trì tính diễn giải được của hệ số hồi quy - có thể đọc trực tiếp chiều và độ lớn tác động của từng biến sinh học lên MMSE.

R^2 âm đồng đều ở tất cả mô hình phản ánh một giới hạn cơ bản của bài toán: với chỉ 4 biến sinh học và 150 bệnh nhân, mô hình hồi quy tuyến tính không đủ năng lực nắm bắt toàn bộ độ phức tạp của quá trình suy giảm nhận thức — một hiện tượng chịu tác động đồng thời của yếu tố di truyền (APOE- $\epsilon 4$), lịch sử bệnh lý, và môi trường sống mà bộ dữ liệu OASIS-2 không thu thập.

2.5. Phân Tích Phần Dư và Đặc Điểm Quan Trọng Nhất

2.5.1. Phân tích phần dư Ridge




Hình 2.8: Các biểu đồ phần dư của Ridge

Nhận xét:

- Residual vs Fitted: Phần dư dương tập trung ở vùng $\hat{y} \in [22, 26]$ và bị nén về âm ở vùng $\hat{y} \in [28, 32]$. Hiện tượng phản ánh đúng giới hạn cứng trên thang điểm 30 của MMSE. Mô hình có xu hướng dự báo vượt ngưỡng cho các bệnh nhân có điểm thực tế cao, tạo ra phần dư âm. Giả thiết về GM1 chưa được thỏa mãn hoàn toàn.
- Normal Q-Q: Hai điểm ngoại lệ bên trái có điểm MMSE thực tế thấp bất thường mà mô hình không dự báo chính xác được. Phần dư thể hiện phân phối đuôi trái nặng, vi phạm nhẹ giả thiết GM5.

- Scale - Location: Đường trend line có độ dốc âm đồng nghĩa tính phương sai sai số không đồng đều chưa khắc phục. Chuẩn hóa L_2 kiểm soát phương sai của hệ số $\hat{\beta}$ nhưng không can thiệp vào phương sai sai số ϵ .
- Residuals vs Leverage: Với phân bố $h_{ii} < 0.063$, leverage chỉ phụ thuộc vào ma trận thiết kế X và hoàn toàn độc lập với λ . Hai điểm ngoại lệ có SE lớn nhưng vẫn nằm ở mức trung bình, không tồn tại điểm nào vừa có phần dư lớn, vừa có leverage cao - cấu trúc mô hình không bị ảnh hưởng.

2.5.2. Đặc điểm quan trọng nhất



Hình 2.9: Độ quan trọng của mỗi đặc điểm

nWBV là đặc trưng có tác động lớn nhất với standardized $\hat{\beta} \approx 2.1$ và khoảng tin cậy hoàn toàn dương $[1.5, 2.8]$. Kết quả này xác nhận trực tiếp cơ chế sinh học của Alzheimer: thể tích não bình thường hóa là chỉ báo định lượng trực tiếp của quá trình teo não — cơ chế nền tảng gây suy giảm nhận thức. Mỗi đơn vị lệch chuẩn tăng thêm của nWBV tương ứng với điểm MMSE tăng thêm 2.1 đơn vị lệch chuẩn sau khi kiểm soát các biến còn lại.

Age có standardized $\hat{\beta} \approx 1.35$ với khoảng tin cậy $[0.75, 2.05]$, là biến có tác động lớn thứ hai. Chiều tác động thuận đã được lý giải ở mục 1.4.1 bởi survival bias — nhưng khoảng tin cậy rộng

cho thấy ước lượng này kém chính xác hơn **nWBV**, phản ánh sự không đồng nhất lớn giữa các bệnh nhân ở cùng độ tuổi.

EDUC có standardized $\hat{\beta} \approx 0.35$ với khoảng tin cậy $[-0.1, 0.85]$ chứa 0, nhất quán với kết quả p-value không có ý nghĩa thống kê ở mục 1.4.1. Dù học vẫn được kỳ vọng tạo cognitive reserve, tác động này không thể hiện rõ trong mẫu nghiên cứu với phạm vi **EDUC** từ 6 đến 23 năm.

SES có standardized $\hat{\beta} \approx -0.5$ với khoảng tin cậy hoàn toàn âm $[-1.05, -0.1]$, xác nhận tác động nghịch có ý nghĩa thống kê. Do thang đo **SES** được mã hóa ngược (1 = cao nhất, 5 = thấp nhất), hệ số âm có nghĩa là vị thế kinh tế xã hội càng cao thì điểm MMSE càng tốt — phản ánh vai trò của điều kiện sống, khả năng tiếp cận chăm sóc y tế và môi trường kích thích nhận thức đối với sức khỏe não bộ ở người cao tuổi.

CHƯƠNG 3

Kết Luận

3.1. Tóm tắt kết quả đạt được

3.2. Khó khăn gặp phải

3.3. Bài học rút ra

TÀI LIỆU THAM KHẢO

- [1] Gilbert Strang. Introduction to Linear Algebra, 6th ed. Wellesley-Cambridge Press, 2023.
- [2] Gareth James, Daniela Witten, Trevor Hastie & Robert Tibshirani. An Introduction to Statistical Learning, 2nd ed. Springer, 2021. <https://www.statlearning.com/>
- [3] Trevor Hastie, Robert Tibshirani & Jerome Friedman. The Elements of Statistical Learning, 2nd ed. Springer, 2009. <https://hastie.su.domains/ElemStatLearn/>
- [4] Christopher M. Bishop. Pattern Recognition and Machine Learning. Springer, 2006. (Chương 3: Linear Models for Regression)
- [5] Kevin P. Murphy. Probabilistic Machine Learning: An Introduction. MIT Press, 2022. <https://probml.github.io/pml-book/book1.html>
- [6] Jake VanderPlas. Python Data Science Handbook. O'Reilly, 2016. <https://jakevdp.github.io/PythonDataScienceHandbook/>
- [7] Wes McKinney. Python for Data Analysis, 3rd ed. O'Reilly, 2022.

DANH MỤC CÁC BẢNG

Bảng 1.1	Các chỉ số đo lường sự biến động trong mô hình hồi quy	10
Bảng 1.2	Kết quả ước lượng các hệ số hồi quy của mô hình	22
Bảng 1.3	So sánh kỳ vọng và trị tuyệt đối sai số chệch (Bias) giữa các phương pháp ước lượng	25
Bảng 1.4	So sánh phương sai (Variance) và tỷ lệ hiệu quả giữa các phương pháp ước lượng	26
Bảng 2.1	Đặc trưng dữ liệu của các thuộc tính quan trọng	29
Bảng 2.2	Thống kê mô tả các biến số	31
Bảng 2.3	Hệ số phóng đại phương sai (VIF) của các biến độc lập	36
Bảng 2.4	OLS Cơ Bản - Hệ số hồi quy tuyến tính của các biến	37
Bảng 2.5	OLS Cơ Bản - Kết quả đánh giá	37
Bảng 2.6	OLS Chọn Biến - Hệ số hồi quy tuyến tính của các biến	38
Bảng 2.7	OLS Chọn Biến - Kết quả đánh giá	38
Bảng 2.8	Ridge - Kết quả đánh giá	40
Bảng 2.9	Kernel Ridge - Kết quả đánh giá	41
Bảng 2.10	Bảng so sánh tổng hợp kết quả giữa các mô hình	42

DANH MỤC CÁC HÌNH ẢNH

Hình 1.1	Đồ thị Residuals vs Fitted	16
Hình 1.2	Đồ thị Normal Q-Q	17
Hình 1.3	Đồ thị Scale - Location	18
Hình 1.4	Đồ thị khoảng cách Cook	19
Hình 1.5	Tổng hợp các đồ thị phân tích phần dư	23
Hình 1.6	Kết quả mô phỏng Monte Carlo	26
Hình 2.1	Heatmap dữ liệu bị khuyết	30
Hình 2.2	Heatmap tương quan giữa các hệ số	32
Hình 2.3	Phân phối của các biến (Histogram)	33
Hình 2.4	Phân phối của các biến (Boxplot)	34
Hình 2.5	Phân phối biến SES trước và sau điều khuyết	35
Hình 2.6	CV Error Curve	39
Hình 2.7	Kernel Ridge - CV MSE theo lưới	41
Hình 2.8	Các biểu đồ phần dư của Ridge	43
Hình 2.9	Độ quan trọng của mỗi đặc điểm	44